

How AI Empowers Innovative Drug Development

严格按提纲结构版


日期：2026-06-16

核心判断：AI 已经显著改变药物研发中的局部效率和工作流，但尚未在行业层面证明能够系统性提高药物获批概率。投资判断围绕证据等级、研发环节、modality 核心瓶颈、商业模式与资产权益展开。

Section 1: 创新药研发流程与传统痛点

本节建立标准化创新药研发底图，明确从 TPP/QTPP、靶点发现、临床前、CMC、IND/CTA、临床试验、注册申报到上市后管理的完整流程。后文所有章节都回扣这一流程，判断 AI 是否真的作用于传统痛点。

图 1 | 创新药开发全流程与 AI 介入 overlay



读图：后续章节均回扣该 common pathway；modality 差异在 Section 4 单独讨论。

1.1 创新药开发全流程

创新药开发从来不是“发现一个分子”这么简单。完整流程包括 TPP/QTPP 与疾病定位、target discovery / validation、assay 建立与 hit discovery、hit-to-lead 与 lead optimization、candidate nomination、IND-enabling 非临床研究、CMC 与 GMP 临床样品、IND/CTA preparation and submission、Phase I/II/III、NDA/BLA/MAA、审评检查标签与 RMP/REMS，以及上市后 PV、RWE 和 CMC lifecycle management。

TPP 更靠近临床和商业定位，回答目标患者、疗效、安全性、给药方式、标签和竞争差异。QTPP 更靠近 CMC 和质量目标，连接剂型、规格、稳定性、杂质、释放特征、分析方法和控制策略。AI 如果介入 TPP/QTPP，本质上更像 portfolio intelligence 或 strategy software；如果介入 hit/lead，则更接近 discovery platform；如果介入 CMC、regulatory writing 或 PV，则更像 regulated enterprise workflow。

VC 尽调中最重要的是把公司能力放回流程中定位。一个只做 hit generation 的平台，不能被自动视作完整药物研发平台；一个只做 regulatory writing 的工具，也不应按 asset biotech 估值。不同环节对应不同买方、预算、证据门槛和估值逻辑。

1.2 时间、成本与失败率

传统创新药开发最耗时的环节通常是临床验证、患者招募、随访、CMC 放大和监管审评。最烧钱的环节通常是 Phase II/III 临床试验、失败项目的沉没成本、CMC/GMP 建设、长期随访与上市后承诺。失败率最高、对资产价值影响最大的节点是 Phase II PoC，因为它首次较系统地检验机制、剂量、人群和 endpoint 是否能转化为人体疗效。

FDA 教育资料显示，Phase I 到下一阶段约 70%，Phase II 到下一阶段约 33%，Phase III 到下一阶段约 25-30%。BIO 2011-2020 行业数据给出 Phase I-to-approval LOA 约 7.9%；Wong/Siah/Lo 的同行评议研究给出约 13.8% 的 Phase I-to-approval POS。不同口径不完全一致，但共同说明 clinical attrition 是药物研发经济模型的核心。

因此，不能把 discovery 提效直接等同于整体研发成功率提高。AI 更快找到 hit 或生成 molecule，只能说明早期搜索效率提高；能否提高 approval probability，要看它是否改善 candidate developability、toxicity、CMC、patient selection、dose selection、endpoint 和临床执行质量。

图 2 | 临床阶段成功率/失败率漏斗（基准，不代表 AI 已改善）



FDA 教育页：Phase I→II 约 70%，Phase II→III 约 33%，Phase III→下一阶段约 25-30%。

BIO 2011-2020：Phase I-to-approval LOA 约 7.9%。

Wong/Siah/Lo：Phase I-to-approval POS 约 13.8%。

VC 含义：Phase II PoC 是验证 AI 是否真正影响成功率的关键断点。

1.3 创新药开发的核心瓶颈

核心瓶颈可分为四类。第一是科学风险，包括靶点验证不足、疾病生物学理解不完整、动物模型不可转化、biomarker 缺失。第二是可开发性风险，包括 potency、selectivity、DMPK、toxicity、off-target、formulation、stability 和 manufacturability。第三是执行与监管风险，包括 IND 材料不完整、临床方案设计不合理、招募慢、protocol amendment、CMC 放大失败、数据完整性问题和监管补件。第四是商业风险，包括竞争格局变化、支付方接受度、label 不足、差异化不够。

AI 的经济价值取决于它作用于哪类瓶颈。文献总结、写作、QC 和 case processing 主要降低人工负担；virtual screening 和 DMTA 优化主要提高速度和部分成本效率；patient stratification、dose selection、endpoint optimization 和 CMC control strategy 才可能影响真实失败率，但证据门槛也更高。

1.4 Section 1 可视化要求

本节可视化包括：药物开发全流程与 AI overlay、Discovery 到 post-market 时间轴、各阶段成功率/失败率漏斗、时间/成本/失败率矩阵和 AI 可介入环节图。这里使用 common drug development pathway，modality 差异在 Section 4 讨论。

环节	主要时间/成本压力	核心失败点	AI 价值假设
Target / Hit	数据与实验循环	biology 不转化、assay artifact	提高发现效率和优先级排序
Lead / Candidate	DMTA 多目标优化	DMPK/tox/developability	缩短周期、改善候选药质量
IND / CMC	材料复杂、GMP 成本	CMC/非临床缺口	减少返工、提高申报完整性
Phase II	临床 PoC	人群/剂量/endpoint 错误	可能影响成功率，但需临床验证
Phase III	招募和运营成本	执行复杂、效应不足	提高招募和运营效率
PV/RWE	持续合规	安全信号与承诺管理	稳定 workflow 收入

Section 2: AI 药物研发的证据与市场热度总览

本节按照 deep-research 的 lit-review / source-verification / synthesis 逻辑重新整理：先界定证据类型，再扩充文献与专利资料，最后把论文、专利、融资、BD 和监管资料映射到投资判断。本节已删除原来的 Section 2 可视化图，并删除 2.2「文献管理与下载」小节；核心文献和专利资料直接内嵌在正文表格中，读者不需要打开任何附件即可理解证据基础。

本次补充资料分成两类，并在正文中完整呈现。第一类是文献资料，覆盖结构预测、生成式化学、virtual screening、ADMET/DMPK/tox、临床成功率基线、研发成本基线、专利文本挖掘、监管 AI 框架等方向。第二类是专利资料，重点不是简单罗列专利号，而是按专利布局主题判断其 VC 含义：哪些是模型/方法专利，哪些可能触及具体分子资产，哪些真正影响 FTO 和商业壁垒。

2.0 AI 应用如何产品化：软件实现与公司例子

AI 药物研发的公开论文通常写“模型能做什么”，但投资研究更需要拆成“软件/平台如何落地”。从公司实现看，AI 应用大致分成六类：研发情报系统、靶点/生物学平台、分子设计平台、实验闭环平台、临床/监管/CMC workflow、上市后 PV/RWE 数据平台。每类产品的买方、数据接入、交付物和商业模式不同，不能都归为“AIDD”。

AI 应用	典型软件/平台实现	真实公司例子	交付物	商业化方式
R&D intelligence / TPP	RAG + 文献/专利/临床试验/指南知识库，竞品标签比较，适应症与 endpoint scoring	BenchSci、Citeline/Trialtrove 类情报平台，pharma 内部 portfolio AI	适应症优先级、竞品格局、endpoint/人群建议	SaaS、enterprise license、咨询化交付
Target discovery / disease biology	knowledge graph、single-cell/multi-omics embedding、perturbation-response model	Recursion、BenevolentAI、Xaira	靶点假设、biomarker、人群分层、候选项目	平台合作、共同开发、自研管线
Small-molecule design	物理建模 + ML、docking/rescoring、GNN、diffusion/generative model、ADMET predictor	Schrödinger、Insilico、Exscientia	hit、lead、candidate、property optimization package	软件 license、平台合作、license-out
Automated wet-lab loop	robotics + assay + active learning + 数据闭环	XtalPi、Recursion、部分自动化实验平台	可复现实验数据、晶型/制剂/活性筛选结果	AI-CRO、平台服务、enterprise collaboration
Clinical / regulatory workflow	patient matching、site selection、regulatory RAG、CSR/CTD consistency checker、audit trail	Saama、Veeva ecosystem、regulatory/PV AI vendors	招募名单、site ranking、submission draft/QC、审计记录	enterprise software、validated workflow
PV/RWE lifecycle	AE NLP、MedDRA coding、signal detection、RWE cohort builder、causal inference pipeline	ArisGlobal、Oracle/Argus ecosystem、ConcertAI 类 RWE 平台	safety case、signal report、RWE evidence package	SaaS、数据服务、managed service

这些实现方式对应不同估值逻辑。分子设计平台若保留资产权益，可以获得 biotech upside；clinical/regulatory/PV 软件若形成企业部署，更接近 vertical SaaS；自动化实验平台若沉淀 proprietary data，则可能形成“服务收入 + 数据壁垒 + 项目权益”的混合模型。因此，Section 2 的证据不只用于判断技术热度，也用于识别公司到底在卖软件、卖服务、卖项目权益，还是卖一个未来管线平台。

2.1 学术论文趋势

文献分布显示，AI 药物研发最活跃的论文区域仍在 discovery 端，尤其是 protein structure prediction、biomolecular interaction prediction、virtual screening、generative chemistry、ADMET/DMPK/tox prediction 和 LLM/agent workflow。Jumper 等人的 AlphaFold2 和 Abramson 等人的 AlphaFold3 属于基础设施级论文，它们显著提高了结构与相互作用建模能力，但证据等级仍主要是 L0/L1；它们证明模型能力，不直接证明某个药物资产的临床成功率会提高。

生成式化学和 virtual screening 的论文热度最高，但商业解释必须克制。Stokes 等人的 halicin 工作和 Zhavoronkov 等人的 DDR1 kinase inhibitor 工作把 AI 从 benchmark 推到 wet-lab / preclinical validation，是相对强的早期证据；但多数 generative chemistry 论文仍停留在模型、benchmark、retrospective validation 或有限 wet-lab 验证。商业化转化指标包括 hit-to-lead、lead-to-candidate、ADMET/DMPK/tox、synthetic accessibility 与 CMC developability。

ADMET、DMPK 和 toxicity prediction 的论文声量不如生成式化学，但更接近 IND 前失败点。很多项目不是死于找不到活性分子，而是死于 PK、toxicity、off-target、metabolism、solubility、formulation 或 developability。该类 AI 如果能缩短 DMTA cycle、减少无效合成、提前暴露 toxic liability，经济价值可能比单纯 hit generation 更扎实。

临床、监管、CMC、PV/RWE 方向的文献数量相对少，但更靠近明确预算和付费场景。FDA 与 EMA 文件已经把 AI 放进药品全生命周期监管语境，强调 context of use、model risk、credibility assessment、human oversight、audit trail、GxP 和 data integrity。换句话说，AI 从 discovery 扩张到 regulated workflow 后，证据标准会从“模型表现好”升级为“模型在特定使用场景下可信、可解释、可追踪、可维护”。

资料	方向	证据等级	VC 含义
AlphaFold2 / AlphaFold3	结构与相互作用预测	L0-L1	基础设施级能力，不等于资产成功率提升
Halicin / DDR1 inhibitor	virtual screening / generative chemistry	L2-L3	AI discovery 走向湿实验与动物验证的代表
Vamathevan / Chen / Hasselgren 等综述	AI discovery 方法版图	L0	支持市场热度和方法成熟度判断
Wong / Wouters	临床成功率与 R&D 成本基线	L7	用于约束“AI 提高成功率/降本”的叙事
PatentAgent / PatentFinder / patent extraction	AI+专利分析	L0-L1	FTO、专利阅读、结构识别成为新 workflow
FDA / EMA AI 文件	监管与全生命周期治理	L7	监管级 AI 需要 context of use、validation 和 audit trail

2.3 专利趋势

AI 药物研发专利不能只看数量。通用 AI 和 generative AI 的专利热度已经很高，但药物研发领域需要进一步拆分：模型/算法专利、数据处理专利、实验自动化专利、工作流专利、具体化合物/序列/用途专利、制造与控制策略专利，对 VC 的含义完全不同。模型专利可以支持平台壁垒，但真正能保护资产经济性的，通常还是 composition-of-matter、method-of-use、formulation、manufacturing process 和可执行的数据/流程壁垒。

Discovery 端的专利主要集中在 generative chemistry、structure-based design、target discovery knowledge graph、phenotypic screening、ADMET/tox prediction。这里最常见的风险是权利要求过宽、容易被替代实现绕开，或无法阻止竞争者用不同模型达到类似输出。因此，平台公司的 IP 尽调不能只问“是否有 AI 专利”，而要问专利是否绑定 proprietary dataset、closed-loop wet lab、具体 target/molecule/sequence、可重复 pipeline，以及是否支持 FTO。

Clinical、regulatory、CMC、PV 端的专利往往不如 discovery 端显眼，但商业壁垒可能更稳定。CMC/formulation/QbD 的专利可能与工艺、晶型、制剂、批次质量预测、控制策略和 GxP 系统集成绑定；clinical trial AI 的壁垒更多来自 patient/site data network 和 workflow integration；regulatory writing 与 PV 的壁垒更多来自 audit trail、validated workflow、source traceability 和客户系统嵌入。

专利主题	代表申请人/平台类型	技术焦点	投资含义
Generative chemistry	Insilico、Exscientia、Recursion、Schrodinger、学术团队	分子生成、属性优化、合成优先级	泛模型专利拥挤；更看重具体化合物/用途/FTO
Structure / interaction prediction	DeepMind、Isomorphic、pharma/academic groups	蛋白结构、蛋白-配体/核酸/抗体相互作用	工具壁垒强，但资产保护仍靠具体药物专利
Target discovery / knowledge graph	BenevolentAI、Insilico、Recursion、pharma data teams	疾病网络、靶点优先级、biomarker	宽泛方法权利要求有限，数据壁垒更重要
Phenotypic image AI	Recursion-like phenomics platforms	high-content imaging、cell painting、扰动响应	数据网络 + 实验闭环比单一算法专利更强
ADMET / DMPK / toxicity	Pharma、CRO、AI-CRO、软件商	毒性、代谢、PK、off-target	前瞻性验证和客户采纳比专利数量重要
CMC / formulation / QbD	Pharma、CDMO、process analytics vendors、XtalPi-like platforms	晶型、制剂、工艺放大、质量预测	被低估；GxP、工厂数据和系统集成形成壁垒
Clinical trial AI	CRO、trial tech、pharma	招募、site selection、enrollment forecast	数据网络和 workflow lock-in 强于算法专利
Regulatory / PV AI	Regtech、安全性软件、pharma	CSR/CTD、case processing、signal detection	audit trail、validation、合规流程决定商业价值

2.4 投融资趋势

融资热度主要流向三类公司：第一类是 foundation-model biology / full-stack AI biotech，强调模型、数据、实验和资产管线整合；第二类是 AI-enabled discovery platform，强调更快找到 hit/lead/candidate 并通过 BD 或自研资产变现；第三类是 clinical/regulatory/CMC/PV workflow infrastructure，强调明确预算、可量化 ROI 和 enterprise workflow。

2021 年高峰期的 AI 药物研发融资往往把“平台能力”提前资本化，而后续市场更关注临床资产、真实收入、BD 现金结构和客户复购。Xaira、Isomorphic、Recursion/Exscientia、XtalPi 等案例显示资本仍愿意押注大平台，但估值逻辑已经从“AI 模型新颖”转向“是否拥有数据、实验闭环、资产推进能力和 pharma 认可”。

2.5 BD 与合作趋势

Pharma 真正愿意付费的能力并不只是“AI”，而是 AI 能否解决药企内部成本高、周期长、失败率高、数据碎片化和人才稀缺的问题。BD 类型从软件 license、项目服务、平台合作到资产 license-out 差别很大。headline deal value 必须拆成 upfront、research funding、option fee、milestones、royalty、equity investment、retained rights 和 data/model ownership。

高质量 BD 的特征是：有明确 upfront 或 research funding；合作对象是高质量 pharma；合作范围能映射到具体 target/modality/stage；后续有项目推进或重复合作；AI 公司保留长期权益。低质量 BD 的特征是只披露 headline value、缺少 upfront、项目范围模糊、没有后续进展验证。

2.6 监管趋势

FDA 和 EMA 的公开文件共同指向一个结论：监管机构并不反对 AI，但会按风险、使用场景和对决策影响程度要求不同证据。AI 用于 discovery 内部启发，与 AI 用于支持 regulatory decision-making 不是同一件事。后者需要 context of use、model credibility、data representativeness、bias control、human oversight、audit trail、change control 和 lifecycle monitoring。

因此，监管既是 adoption 障碍，也可能形成壁垒。短期内，监管要求会增加 AI 工具进入 GxP、submission、PV、CMC 体系的成本；长期看，能提供 validated workflow、traceable evidence package、enterprise integration 和监管沟通经验的公司，反而可能比纯 discovery 模型公司更早形成稳定收入。

Section 3: AI 如何嵌入创新药研发流程

本节按创新药研发流程拆解 AI 的真实嵌入点。每个小节均按照“传统痛点 → AI use case → 技术成熟度/证据 → 商业验证/代表案例 → 投资含义”的逻辑展开，并回扣 Section 2 的文献、专利、BD 和监管资料。

图 3 | AI use case：速度、成本、成功率、商业化、证据强度

	速度	成本	成功率	商业化	证据
TPP/QTPP	3	2	2	3	2
Target	3	2	4	3	2
Hit	5	4	2	5	3
Lead/ADMET	4	4	3	5	3
CMC	3	4	3	4	2
IND/CTA	3	3	2	4	2
Phase I	2	2	3	3	2
Phase II	2	3	5	3	2
Phase III Ops	4	5	2	5	3
Reg Writing	4	4	2	5	3
PV/RWE	4	5	2	5	3

1=低，5=高；该图是 VC 初筛判断，不是确定性临床结论。

3.1 TPP / QTPP 与疾病定位

可落地技术包括：基于 RAG 的 evidence synthesis agent、biomedical entity recognition、indication/endpoint ontology mapping、trial landscape clustering、LLM + citation grounding 的竞品标签比较，以及基于 RWD 的患者人群聚类 and unmet-need scoring。这里的核心模型不是分子生成模型，而是能把 guideline、label、trial registry、RWD、文献和专利资料统一成可追踪决策图谱的 enterprise intelligence system。

传统痛点在于早期产品定位常常依赖专家经验和有限竞品信息，TPP 对目标患者、疗效、安全性、给药方式、endpoint、label 和差异化要求描述不足，导致后续发现出来的资产即使有活性，也未必符合临床和商业需求。QTPP 则更靠近 CMC 和质量目标，如果早期没有把剂型、稳定性、给药便利性、杂质和工艺可行性纳入设计，后期返工成本会很高。

AI 可用于整合指南、文献、ClinicalTrials.gov、RWD、竞品标签、支付方资料和专利信息，辅助适应症选择、患者人群切分、endpoint 选择、竞品 landscape 和目标产品属性推演。这类工具的技术形态更像 portfolio intelligence、strategy software 或 evidence synthesis agent，而不是狭义 drug discovery platform。其输出不直接生成分子，但会影响“做什么药、给谁用、以什么 endpoint 证明价值”。

投资含义上，这类方向短期商业化可行，但估值上限取决于是否嵌入 pharma portfolio decision workflow。若只是生成市场综述，容易被咨询和内部团队替代；若能把 RWD、专利、临床试验、指南和商业模型连接成可追踪决策系统，并持续影响项目立项、BD 和临床设计，则更有软件平台价值。

3.2 Target Discovery / Biomarker / Disease Biology

可落地技术包括：heterogeneous biomedical knowledge graph、graph neural network link prediction、multi-omics autoencoder、single-cell foundation model、causal representation learning、CRISPR perturbation response model、Bayesian network、Mendelian-randomization-inspired target prioritization，以及 patient-level embedding 用于 biomarker 和亚群识别。高质量平台通常不是单一模型，而是“多组学 + 人类遗传学 + perturbation + wet-lab feedback”的证据栈。

传统靶点发现最大的风险不是找不到候选靶点，而是靶点与人类疾病因果关系不足。许多项目在细胞或动物模型中成立，却无法转化到人群；biomarker 缺失会进一步导致临床试验入组人群混杂、疗效信号被稀释。单细胞、多组学、遗传学、蛋白组学、空间组学和 RWD 数据使靶点发现更数据化，但也带来噪声、批次效应和因果解释困难。

AI 的 use case 包括多组学整合、知识图谱、causal inference、disease module identification、target prioritization、biomarker discovery 和 patient stratification。Section 2 的文献显示，结构预测和 foundation model biology 提供了新基础设施，但靶点发现真正的壁垒仍在 proprietary human biology data 和 wet-lab/clinical feedback loop。模型能提出靶点假设，不等于靶点已被验证。

该方向的重要展开点是“证据闭环”。高质量平台应能说明：靶点来自什么数据，是否有人类遗传学或临床样本支持，是否经过 CRISPR/perturbation/animal model 验证，是否能形成可测 biomarker，是否能前置到患者分层。VC 不应只看靶点数量，而应看 target-to-program conversion、program-to-candidate conversion，以及是否已有 partner 或自研管线证明平台可重复。

专利层面，target discovery 常见的是知识图谱、数据处理、特征提取和靶点排序方法。宽泛算法专利很难单独构成强 FTO 壁垒；更强的是 proprietary datasets、实验扰动数据、临床样本网络和与具体靶点/适应症绑定的资产专利。代表公司包括 Recursion、Insilico、BenevolentAI 和多家 pharma 内部 AI biology team。

3.3 Hit Discovery / Virtual Screening / Generative Chemistry

可落地技术包括：structure-based docking + ML rescoring、3D equivariant GNN、protein-ligand interaction model、molecular diffusion model、VAE/GAN/RNN/Transformer-based de novo design、reinforcement learning for molecular optimization、active learning screening、synthetic accessibility prediction、retrosynthesis model，以及 AlphaFold/AlphaFold3-like structure or interaction input。应用层通常表现为 virtual screen、fragment growing、scaffold hopping、hit expansion 和 novelty/FTO pre-check。

传统 hit discovery 的痛点是化学空间巨大、HTS 成本高、筛选库覆盖有限、assay artifact 常见，并且早期 hit 很多并不具备后续优化价值。虚拟筛选和生成式化学可以显著降低搜索成本，让团队更快获得结构多样的候选分子，但这只是 discovery 价值链的入口。

AI use case 包括 docking acceleration、ligand-based virtual screening、structure-based design、generative model、reinforcement learning、multi-objective optimization、synthetic accessibility prediction 和 active learning。Section 2 中 halicin、DDR1 inhibitor、AlphaFold 系列和 generative chemistry 综述共同说明：AI 已能提高 early search efficiency，并在部分案例中走到 wet-lab / animal validation。

重要部分在于区分“生成分子”和“生成可开发资产”。生成模型容易产出看似新颖的结构，但这些结构可能不可合成、IP/FTO 风险高、ADMET 差、选择性不足或 CMC 不友好。真正有价值的 closed-loop platform 应把模型、合成、assay、DMPK 和 tox 数据连成 DMTA 循环，让每轮实验反馈都改善下一轮设计。

投资含义上，hit discovery 平台竞争最拥挤，单纯模型能力容易被压成 AI-CRO 或 project service。更值得投的是能证明 hit-to-lead、lead-to-candidate、IND-enabling package 或 clinical entry 的团队；若公司只展示 benchmark、生成数量和漂亮分子图，而缺少湿实验转化率和资产推进证据，估值应明显打折。

3.4 Lead Optimization / ADMET / DMPK / Toxicity Prediction

可落地技术包括：multi-task QSAR、graph neural network property predictor、message-passing neural network、Gaussian process / Bayesian optimization、multi-objective Pareto optimization、uncertainty quantification、active learning DMTA planner、hERG/CYP/off-target classifier、metabolism site prediction、PBPK/PK model surrogate，以及 tox endpoint 的 domain-of-applicability filter。关键不是单项 AUC，而是能否在一个化学系列内稳定指导下一轮合成。

Lead optimization 的传统痛点是多目标冲突：potency、selectivity、solubility、permeability、metabolic stability、clearance、hERG、CYP、toxicity、formulation 和 synthetic tractability 往往互相牵制。项目失败很多发生在“有活性但不可开发”，而不是“完全没有活性”。

AI 可以通过 QSAR、多任务学习、图神经网络、active learning、Bayesian optimization 和 uncertainty estimation 缩短 DMTA cycle。它的目标不是替代药化团队，而是减少无效合成、提前识别 developability risk，并帮助团队在 potency 与 ADMET 之间做更系统的 trade-off。Section 2 的证据表明，这类方向论文声量不一定最高，但更接近 IND 前真实失败点。

重要展开点是模型验证。ADMET/tox 预测必须面对数据异质性、实验条件不一致、外推失败和 domain-of-applicability 问题。一个模型在公开 benchmark 表现好，不代表在某个化学系列、某个 target family 或某个 assay 条件下可靠。高质量平台应报告 prospective validation、uncertainty、negative examples、wet-lab closed loop 和项目级节省的合成/实验轮次。

投资含义上，这是 discovery 端更可投资的环节之一，因为它直接影响 candidate quality 和 IND 前失败风险。商业模式可以是软件、AI-CRO、platform collaboration 或 asset-centric biotech；但核心尽调问题始终是：AI 是否让候选药更可开发，而不仅是更快生成。

3.5 CMC / Formulation / Manufacturing / QbD

可落地技术包括：Bayesian optimization for formulation/process parameters、digital twin of manufacturing process、multivariate process control、PAT spectral model、anomaly detection、time-series batch quality prediction、crystal-form prediction、surrogate model for process scale-up、root-cause analysis graph，以及与 LIMS/MES/QMS 对接的 validated workflow。这里的 AI 更接近工业建模和质量系统，而不是药化生成模型。

CMC 的传统痛点包括晶型/盐型选择、制剂稳定性、杂质控制、分析方法开发、工艺放大、批间一致性、GMP 数据完整性和变更管理。很多 AI drug discovery 叙事忽视 CMC，但任何候选药进入临床和商业化都必须跨过这道门槛。

AI use case 包括 crystal form prediction、formulation optimization、process parameter modeling、batch failure prediction、deviation investigation、PAT 数据分析、release analytics 和 QbD/control strategy support。相比 de novo discovery，CMC AI 的买方预算更明确，ROI 也更容易以返工减少、批次失败下降、放大周期缩短和质量事件降低来衡量。

专利和壁垒上，CMC AI 不一定依赖显眼的算法专利，而是依赖工艺数据、GxP 验证、系统集成和客户切换成本。对 CDMO、pharma manufacturing、formulation team 和质量部门而言，一个可验证、可审计、可接入 LIMS/MES/QMS 的 AI workflow 比单独模型更有价值。

投资含义上，这是被低估的方向。它可能不会产生“AI 自动发现新药”的叙事张力，但更容易形成企业级软件收入和深 workflow lock-in。风险在于销售周期长、验证成本高、客户数据接入困难，以及需要懂 GMP/QA/CMC 的复合团队。

3.6 IND / CTA Preparation and Submission Intelligence

可落地技术包括：regulatory RAG、structured document parser、cross-document consistency checker、IND readiness rule engine、nonclinical/CMC gap detection classifier、dose-rationale evidence linker、submission checklist ontology、traceable table-to-text generation，以及 human-in-the-loop QC dashboard。模型输出必须带来源定位、版本号、审阅人和证据链，不能只是普通 LLM 摘要。

IND/CTA 是从临床前走向人体试验的监管闸口，传统痛点是 CMC、非临床、安全性药理、毒理、PK/PD、临床方案、IB、risk mitigation 和统计设计资料分散，项目团队需要在短时间内判断材料是否足以支持 FIH 或早期临床。材料缺口会导致监管问询、补充实验、时间延误甚至项目暂停。

AI 可用于 IND gap analysis、briefing book drafting、dose rationale support、nonclinical package cross-check、CMC readiness checklist、protocol consistency review 和 submission QC。这类 AI 的价值不在“替代法规负责人”，而在减少遗漏、提高跨文档一致性、加速证据索引，并把历史监管问题转化为可复用 checklist。

监管要求上，IND/CTA intelligence 属于高敏感 workflow。若 AI 输出会影响 dose、risk mitigation 或监管答复，就必须有 source traceability、version control、human review、audit trail 和 model governance。FDA 2025 draft guidance 对支持监管决策的 AI 强调 context of use 和 credibility assessment，这直接适用于此类工具。

投资含义上，3.6 与 3.10 要区分：3.6 更偏早期临床前到 IND/CTA 的闸口准备，3.10 更偏 CSR、CTD、NDA/MAA 和审评问答。3.6 的商业化对象是 early development、regulatory affairs、toxicology、CMC 和 clinical pharmacology 团队，适合做 regulatory-grade workflow software。

3.7 Translational Medicine / Phase I / Dose Finding

可落地技术包括：population PK/PD model、Bayesian dose escalation model、model-informed drug development simulator、exposure-response modeling、joint longitudinal-survival model、biomarker response model、early safety signal classifier、dose individualization algorithm，以及 adaptive escalation decision support。这里 AI 应与传统 pharmacometrics 结合，而不是脱离药理机制单独预测。

Phase I 的传统目标是安全性、耐受性、PK 和初步 PD，但真正影响后续价值的是 dose selection、exposure-response、biomarker strategy 和早期 go/no-go 判断。如果 Phase I 只完成安全性检查，却没有为 Phase II 提供清晰剂量、人群和机制证据，后续 PoC 失败风险会很高。

AI 可用于 PK/PD modeling、exposure-response analysis、dose escalation simulation、biomarker signal detection、early efficacy signal integration 和 safety monitoring。与传统 model-informed drug development 相比，AI 的潜在增量在于整合更多数据类型，并在实时或近实时试验执行中辅助决策。

证据要求上，Phase I AI 不能只靠 retrospective model performance。若模型会影响剂量递增、停药规则或人群扩展，需要前瞻性验证、临床药理解释、统计控制和 human oversight。它更像 clinical decision support + quantitative pharmacology infrastructure，而不是单纯算法产品。

投资含义上，该方向价值在于减少剂量选择错误、提高 Phase II 设计质量，并为 patient selection 和 endpoint strategy 提供依据。买方是 clinical pharmacology、translational medicine、biometrics 和 early clinical development 团队；壁垒来自数据、模型可信度和嵌入临床决策流程。

3.8 Phase II / PoC / Patient Selection / Endpoint Optimization

可落地技术包括：causal ML、uplift modeling、predictive enrichment model、digital twin / external control matching、propensity score / doubly robust estimator、survival model、Bayesian adaptive design simulator、endpoint sensitivity model、subgroup discovery with multiplicity control，以及 biomarker-threshold optimization。重要的是把模型假设写进 prospective protocol 和 statistical analysis plan，而不是事后挖亚组。

Phase II 是 AI 药物研发价值验证的关键节点，因为它首次系统检验机制、剂量、人群和 endpoint 是否能转化为人体的疗效。传统痛点是患者异质性高、biomarker 不充分、endpoint 选择不敏感、剂量错误、样本量不足或对照组设计不合理。许多项目在 Phase II 失败后，才发现早期假设没有被充分检验。

AI use case 包括 patient stratification、biomarker-enriched design、endpoint optimization、adaptive design support、external control/RWD matching、subgroup discovery 和 trial simulation。相比单纯提高招募速度，这些 use case 更可能影响成功率，因为它们直接作用于 PoC 信号是否能被正确观察。

重要展开点是证据门槛。AI 如果只是事后解释哪些患者反应好，价值有限；如果能在试验前定义 enriched population、剂量策略和 endpoint，并在统计方案中预先说明，就更有可能影响 PoC 成功率。RWD/external control 也不能被泛化使用，必须证明数据可比性、缺失机制、偏倚控制和监管接受度。

投资含义上，这是高价值但高风险方向。若公司能拿出多个前瞻性试验中 AI 改善 patient selection 或 endpoint decision 的证据，其价值远高于普通 discovery tool；但如果证据仅来自 retrospective subgroup mining，应把它视为 hypothesis generation，而不是成功率提升证明。

3.9 Phase III / Recruitment / Site Selection / Trial Operations

可落地技术包括：patient-trial matching NLP、EHR phenotyping model、site performance ranking model、enrollment forecasting time-series model、screen-failure classifier、protocol complexity score、risk-based monitoring anomaly detection、query prioritization model、dropout prediction，以及 clinical operations command-center optimization。应用重点是 trial execution ROI，而不是声称药物疗效被 AI 改善。

Phase III 的传统痛点主要是执行复杂、成本高、招募慢、site 表现差、protocol amendment 多、数据质量和风险审查压力大。这里 AI 未必改变药物本身疗效，但可以显著影响试验速度、成本和执行质量。

AI 可用于 patient matching、site selection、enrollment forecasting、protocol feasibility、risk-based monitoring、query prioritization、dropout prediction 和 operational command center。与 discovery AI 相比，这类产品的买方和预算更清晰，通常是 pharma clinical operations、CRO、site network 和 trial technology team。

证据上, Phase III operations AI 更容易用 operational KPI 验证, 例如启动时间、入组速度、screen failure rate、site productivity、monitoring workload、protocol deviations 和 data cleaning cycle time。它不应被包装为“提高药物本身成功率”, 除非能够证明它改善了代表性、依从性、endpoint capture 或偏倚控制。

投资含义上, 该方向适合企业软件和数据网络模型。壁垒来自与 EHR、site network、CRO workflow、EDC/CTMS/eTMF 系统的整合, 以及跨项目积累的 operational dataset。风险在于采购周期长、客户定制重、与大型 CRO/平台厂商竞争。

3.10 Regulatory Writing / CTD / CSR / NDA-MAA Submission Intelligence

可落地技术包括: grounded LLM writing system、RAG over eTMF/EDC/SAP/TLF/CSR source package、structured CTD module assembler、controlled natural language generation、claim-source alignment checker、citation/anchor validator、version-diff model、label comparison engine、regulatory Q&A retrieval system, 以及 GxP audit logging。高质量产品必须能证明每一句关键结论来自哪张表、哪个版本、哪份源文件。

晚期注册写作的传统痛点是文档量巨大、跨模块一致性难、数据来源复杂、版本控制压力大, 且任何 hallucination、错引、遗漏或不一致都可能引发监管问询。CSR、CTD、NDA/BLA/MAA、审评问答和标签谈判需要高度可追踪的证据链。

AI 可用于 CSR draft、CTD module assembly、cross-document consistency check、table-to-text generation、source traceability、response letter drafting、label comparison 和 submission readiness QC。它的价值主要是降低人工负担、减少一致性错误、加快文档周转, 而不是替代法规策略判断。

重要展开点是 regulatory-grade workflow。通用 LLM 不能直接进入注册写作核心流程, 除非系统具备 retrieval grounding、权限控制、审计追踪、版本管理、引用定位、人工批准、模型变更记录和输出验证。FDA/EMA 对 AI 的监管态度意味着, 这类工具越靠近正式申报材料, 越要像质量体系软件而不是聊天机器人。

投资含义上, 3.10 的短期商业化潜力可能高于很多 de novo discovery 公司, 因为买方痛点明确、ROI 可量化、客户愿意为合规效率付费。估值上限取决于是否能成为 regulatory operating system, 并延伸到 label intelligence、审评问答知识库和全球申报复用。

3.11 Pharmacovigilance / RWE / Post-market Lifecycle

可落地技术包括: AE case intake NLP、duplicate case detection、MedDRA auto-coding model、literature surveillance classifier、disproportionality signal detection、Bayesian safety signal model、RWE cohort builder、causal inference pipeline、label-change intelligence、post-market commitment tracker, 以及 human review queue optimization。这里 AI 的核心是提高安全性工作流吞吐量和一致性, 同时不能牺牲漏报控制。

上市后阶段的传统痛点是安全性病例量大、信号检测复杂、RWE 研究设计难、标签更新和风险管理承诺需要持续跟踪。PV 是高度规范化、重复性高且成本持续发生的 workflow, 因此天然适合 AI automation 和 decision support。

AI 可用于 adverse event case intake、literature screening、duplicate detection、MedDRA coding support、signal detection、case narrative drafting、RWE cohort construction、label expansion evidence review 和 post-market commitment tracking。与 discovery 不同, PV/RWE 的价值更多是稳定合规收入和运营效率, 而不是单个资产爆发式上行。

监管和证据要求同样严格。PV AI 必须处理数据隐私、可解释性、误报/漏报、审计追踪和人工复核; RWE AI 则需要控制 confounding、selection bias、data provenance 和 endpoint definition。若 AI 输出影响安全性判断或监管提交, 必须保留完整证据链。

投资含义上, PV/RWE 是更成熟的付费场景, 适合软件、数据平台和 managed service 混合模式。上限取决于是否能连接药品全生命周期: 从上市后安全性, 到标签扩展、真实世界疗效、风险管理和 CMC lifecycle commitment。

Section 4: 不同创新药 Modality 的开发路径差异、AI 加速潜力与公司 Case Report

本节以真实公司为主线，而不是只按技术分类。每个 modality 选取一个典型公司或可跟踪平台，说明其 AI 如何应用、软件/平台怎样实现、如何获得收入或资产权益、融资/BD 信号是什么，以及其局限性。公开资料不足的方向会明确标注“验证不足”，避免把产业愿景写成已经成立的事实。

图 4 | 不同 Modality 的 AI 加速潜力与核心瓶颈

Modality	AI 切入点	核心瓶颈	验证速度	资产上限
小分子	Hit/Lead/ADMET	临床转化		
抗体/蛋白/双抗	设计/可开发性	CMC/免疫原性		
ADC	组合/毒性/分层	治疗窗		
小核酸/RNA编辑	序列/off-target	递送		
mRNA/RNA疫苗	序列/LNP/抗原	CMC/递送		
细胞治疗	制造/患者筛选	一致性/安全		
基因治疗/编辑	gRNA/capsid	递送/长期安全		
核药	影像/dosimetry	供应链/渠道		

小节	主案例公司	对应 modality / 场景	AI 应用与产品形态	商业/融资/BD 信号	主要局限
4.1	Schrödinger / Insilico	小分子	物理建模 + ML、generative chemistry、ADMET/DMTA	Novartis 合作、Insilico 临床资产	小分子 AI 拥挤，需临床/BD 验证
4.2	Isomorphic Labs / Absci	蛋白、抗体、双抗	AlphaFold 系列、protein/antibody design engine	Novartis/Lilly 合作、外部融资、Absci 产业合作	结构预测不等于可开发 biologics
4.3	BigHat Biosciences	ADC enabling / 抗体工程	AI antibody optimization，可作为 ADC 抗体组件能力	与 pharma 的抗体优化合作信号	公开 AI+完整 ADC 验证有限
4.4	Deep Genomics	小核酸 / RNA therapeutics	AI Workbench 用于 RNA biology、splice/sequence 设计	以 RNA 资产和平台融资为核心	delivery 与临床验证仍是瓶颈

小节	主案例公司	对应 modality / 场景	AI 应用与产品形态	商业/融资/BD 信号	主要局限
4.5	Moderna / BioNTech	mRNA / RNA 疫苗	mRNA sequence design、neoantigen selection、digital CMC	mRNA 平台商业化先例	AI 增量需与临床和制造区分
4.6	Cellares	细胞治疗制造	Cell Shuttle 自动化制造、工艺数据闭环	与细胞治疗公司合作、制造平台化	更偏 manufacturing infrastructure
4.7	Dyno Therapeutics	基因治疗 / AAV capsid	ML-guided capsid engineering	多个 pharma/gene therapy 合作	递送和长期安全性需临床证明
4.8	Ratio Therapeutics / radiopharma AI tools	核药	ligand selection、dosimetry、影像/患者选择	radiopharma 资本热度上升	AI 公开验证仍早期
4.9	Recursion / XtalPi	横向平台	phenomics + automation / quantum+robotics	IPO、合作、并购、平台整合	平台估值最终仍受临床和现金流约束

4.1 小分子药物：Schrödinger 与 Insilico Medicine

小分子是 AI 药物研发最成熟的战场。Schrödinger 的核心不是单纯“AI 生成分子”，而是 physics-based modeling、free-energy calculation、enterprise informatics 与 ML 模型的组合软件栈；它既能卖软件 license，也能通过 discovery collaboration 获得 upfront、milestone、royalty 或候选物权益。公开报道的 Novartis 合作披露了较清晰的 upfront 与 milestone 结构，是“小分子软件平台 + 药企合作”的典型商业验证。

Insilico Medicine 则更接近 asset-centric AI biotech。其路径是从 target discovery、generative chemistry、lead optimization 到临床资产推进，把 AI 平台能力转化为自研或合作资产。Rentosertib/ISM001-055 被公开讨论为 AI-linked clinical asset，价值在于把证据层级从 L0/L2 推向临床阶段，而不是只停留在生成式化学论文。

软件实现上，小分子平台通常包括 compound library、docking/rescoring、3D molecular representation、GNN/diffusion/generative model、ADMET predictor、retrosynthesis 和 project dashboard。落地流程是：模型生成或筛选分子，药化团队筛选可合成结构，湿实验反馈活性和 ADMET，平台用 active learning 更新下一轮 DMTA。投资上限取决于该闭环能否稳定输出 candidate，而不是分子生成数量。

4.2 抗体 / 蛋白药 / 双抗：Isomorphic Labs 与 Absci

Isomorphic Labs 是 foundation-model biology 的代表。它从 DeepMind/AlphaFold 技术体系延伸到药物设计，公开合作包括与 Novartis、Lilly 的 AI drug discovery collaboration，并在 2025 年完成外部融资。它的 case 说明大药企愿意为蛋白结构、相互作用预测和 drug design engine 付费，但合作到临床资产之间仍需要后续 target、candidate 和 IND 披露。

Absci 更偏抗体和蛋白设计平台，结合 synthetic biology、high-throughput wet lab 和生成式 AI 来设计 biologics。对 biologics 来说，AI 软件不仅要预测 binding，还要处理 expression、aggregation、immunogenicity、developability 和 manufacturing。真正可投资的不是“能设计抗体序列”，而是能产生 drug-like antibody，并降低后续 CMC 和免疫原性风险。

软件实现上，这类平台包括 protein language model、structure-conditioned generation、CDR design、binding affinity predictor、immunogenicity classifier、developability filter 和 wet-lab expression/affinity feedback。商业模式可以是平台合作、资产共同开发、内部管线或与硬件/GPU厂商合作降低训练成本。估值差异来自是否能从工具能力走到具体 antibody/protein asset 权益。

4.3 ADC / 靶向偶联药物：BigHat Biosciences 作为 ADC enabling case

AI+ADC 的公开完整案例仍少，因此本节选 BigHat Biosciences 作为“ADC enabling”而非完整 ADC 公司案例。BigHat 的核心能力是 AI-assisted antibody design / optimization：通过实验数据和模型迭代优化抗体亲和力、稳定性、表达和 developability。ADC 的 antibody component 正是影响 internalization、组织选择性和治疗窗的重要组成部分。

ADC 的完整价值链还包括 linker、payload、DAR、旁观者效应、毒性和患者分层。AI 在这里不能只优化抗体结合，还要帮助判断 payload 暴露、正常组织表达、毒性窗口和 biomarker selection。公开资料不足以证明某个 AI 平台已经系统性提升 ADC therapeutic index，因此报告中应把该方向定位为“产业痛点强、公开验证早期”。

软件实现上，ADC AI 可包括 target expression atlas、antibody internalization model、linker-payload property predictor、toxicity classifier、PK/PD exposure model 和 patient biomarker selection。公司 case 的评估重点是：平台是否能拿到真实 ADC 项目数据，是否能在动物或临床中证明治疗窗改善，是否拥有 antibody/linker/payload/用途专利组合。

4.4 小核酸药物：Deep Genomics

Deep Genomics 是 AI+RNA therapeutics 的典型示例。它的商业逻辑不是普通药物软件，而是用 AI Workbench 等平台理解 RNA biology、splicing、variant effect 和 oligonucleotide design，再形成内部 RNA therapeutic pipeline。该 case 说明 AI 可以从“序列设计工具”变成“RNA 资产生成引擎”。

小核酸方向的关键不只是找到序列。ASO/siRNA/miRNA/RNA editing 都要面对 off-target、免疫刺激、化学修饰、组织递送、剂量窗口和长期安全性。AI 软件实现通常包括 sequence-to-effect model、splice impact predictor、off-target scanner、chemical modification optimizer、tissue expression map 和 patient genotype matching。

商业模式上，Deep Genomics 类公司更接近 asset-centric platform biotech：外部融资支撑平台和管线，价值兑现依赖候选药推进、临床数据或 BD。投资变量包括是否有 proprietary RNA biology data、是否能形成 sequence/modification/delivery/IP 组合、是否能突破肝外递送和特定适应症的患者选择。

4.5 mRNA / RNA 药物与疫苗：Moderna 与 BioNTech

Moderna 和 BioNTech 不是纯 AI 公司，但它们是 RNA 平台如何产品化和工业化的关键参照。AI 在 mRNA/RNA 疫苗中的应用包括 codon optimization、UTR design、secondary structure prediction、translation efficiency、stability、neoantigen selection、LNP/formulation optimization 和 digital CMC。

这类公司给 AI 药物研发的启发是：平台价值不来自单个算法，而来自序列设计、制造、质量控制、临床验证和商业化供应链的完整体系。AI 可以提高设计和迭代速度，但最终估值仍由临床数据、适应症空间、制造能力和商业化能力决定。

软件实现上，mRNA 平台通常需要 sequence design engine、antigen/neoantigen ranking、LNP formulation model、batch analytics、stability prediction 和 clinical immunogenicity database。对早期 AI-RNA 公司而言，若没有递送、CMC 和临床验证，仅靠 sequence generator 很难形成高壁垒。

4.6 细胞治疗：Cellares

细胞治疗的主要 bottleneck 常常不是靶点设计，而是制造一致性、产能、成本、批次失败和物流。Cellares 是可跟踪的细胞治疗 manufacturing infrastructure case，其 Cell Shuttle 等自动化系统试图把细胞治疗制造从高度人工流程转向封闭、自动化、可扩展的生产平台。

AI 在这里的应用形态包括 batch quality prediction、process deviation detection、cell-state analytics、release testing prioritization、manufacturing scheduling 和 chain-of-identity / chain-of-custody 数据系统。与 discovery AI 相比，这类公司不一定拥有药物资产，但能通过制造平台嵌入多个细胞治疗项目。

商业模式接近 CDMO + automation platform + data infrastructure。估值变量包括：系统是否能降低 batch failure、是否兼容多种细胞治疗工艺、是否有客户项目、是否能满足 GMP 和监管审计，以及是否形成跨客户的 process data advantage。

4.7 基因治疗 / 基因编辑：Dyno Therapeutics

Dyno Therapeutics 是 AI-enabled AAV capsid engineering 的代表。基因治疗的核心瓶颈之一是递送：组织特异性、免疫原性、装载能力、剂量、安全性和可制造性都会决定资产能否进入临床。Dyno 的平台逻辑是用 ML-guided design 和实验筛选数据优化 capsid，而不是只做 gRNA 设计。

软件实现上，这类平台包括 protein sequence model、library design、fitness prediction、directed evolution surrogate model、tissue tropism classifier、immunogenicity/developability filter 和 wet-lab screening loop。商业模式常见为与 gene therapy 公司或大药企合作，平台提供 capsid 或 delivery component，合作方推进具体治疗资产。

估值变量包括：capsid 是否有强 IP、是否有体内组织选择性数据、是否能降低剂量和免疫风险、是否能被多个 payload/indication 复用，以及合作中平台公司是否保留 downstream economics。该方向的 AI upside 高，但长期安全性和临床转化仍是硬门槛。

4.8 核药 / Radiopharmaceuticals：Ratio Therapeutics 与影像/剂量学 AI

核药 AI 的公司案例仍处于早期，本节用 Ratio Therapeutics 和 radiopharma AI imaging/dosimetry 工具作为跟踪对象。核药的核心不仅是 ligand design，还包括 target expression、patient selection、dosimetry、isotope supply、半衰期、制造物流和医院渠道。

AI 可落地的软件包括 PET/SPECT image segmentation、lesion detection、patient eligibility scoring、absorbed-dose modeling、radioligand property predictor 和 therapy response model。与小分子不同，核药 AI 更贴近 clinical development 和 commercialization infrastructure，因为患者筛选和剂量优化会直接影响试验设计、疗效和安全性。

商业模式可能包括 radiopharma asset platform、影像/剂量学软件、临床试验支持和诊疗一体化数据平台。公开 AI 验证仍少，因此估值应更依赖 radiopharma 资产质量、同位素供应、临床数据和医院网络，而不是 AI 标签本身。

4.9 横向平台：Recursion 与 XtalPi

Recursion 是 phenomics + automation + AI 平台的代表。其核心是高通量细胞成像、扰动实验、机器学习表征和大规模数据集，商业上既有内部管线，也有 Roche/Genentech、Bayer、NVIDIA 等合作/投资信号。Recursion 还通过并购 Exscientia 补充分子设计能力，体现平台整合趋势。


XtalPi 是中国 AI+robotics/quantum chemistry/solid-state/formulation 平台代表。其 case 说明 AI drug discovery 公司不一定选择承担完整临床资产风险，也可以通过实验自动化、晶型/制剂、材料发现和 pharma 服务形成收入。其港股 IPO 提供了资本市场对 AI+robotics R&D infrastructure 的定价样本。

横向比较看，Recursion 更像“数据飞轮 + 管线 + BD”的 full-stack biotech，XtalPi 更像“AI+自动化实验基础设施 + 服务/合作”的 platform service 公司。两者共同说明：平台公司需要把 AI 从算法变成工业化流程，才能获得持续融资和大客户合作；但最终估值仍会回到收入质量、现金消耗、管线进展和合作兑现。

Section 5: AI 药物研发公司的商业模式、公司 Case Report 与 VC 估值逻辑

本节以已获得融资、上市、BD 或产业合作验证的公司为主线，回答三类问题：AI 公司如何赚钱，如何获得资产权益，如何被估值。与传统药物研发公司相比，AI 医药公司的估值多了一层“平台/数据/软件”逻辑，但只要进入临床资产阶段，仍要回到传统 biotech 的 target、indication、PoC、IP、CMC 和竞争格局。

图 5 | AI 药物研发商业模式：收入确定性 vs 资产上限



商业模式	典型公司	AI / 软件实现	赚钱方式	资产权益	估值逻辑
SaaS / license	Schrödinger	physics-based modeling + ML + enterprise informatics	software license、enterprise agreement	部分合作资产权益	SaaS 收入 + 平台合作 + 管线 option
AI-CRO / platform service	XtalPi	quantum chemistry、robotics、crystal/formulation prediction	项目服务、平台合作、自动化实验	通常较少，视合作结构	服务收入 + 数据/自动化平台壁垒
Platform collaboration	Recursion / Isomorphic	phenomics/foundation biology + drug design engine	upfront、research funding、milestone、royalty	program rights / option / royalty	partner 质量 + 真实现金 + 项目推进

商业模式	典型公司	AI / 软件实现	赚钱方式	资产权益	估值逻辑
Asset-centric AI biotech	Insilico	target discovery + generative chemistry + clinical asset	融资、自研资产、 license-out	高	临床资产 RNPV + 平 台溢价
Full-stack AI biotech	Recursion / Xaira	数据、模型、自动化实验、管 线整合	融资、BD、管线价 值	高但资本消 耗大	数据飞轮 + 多管线组合 + burn rate
Clinical/CMC/regulatory infrastructure	XtalPi / Saama / PV-RWE vendors	validated workflow、clinical ops AI、CMC analytics	enterprise software、 managed service	通常低	ROI、GxP、 系统集成、 续费
Venture studio / NewCo	AION Labs	pharma challenge + AI startup creation	pre-seed/NewCo equity、合作权益	取决于 NewCo	pharma 需 求牵引 + 资 产治理

5.1 SaaS / Software License: Schrödinger

Schrödinger 是最适合说明 AI/计算药物发现 SaaS 逻辑的公司。它的软件并不是简单聊天式 AI，而是把 molecular simulation、free-energy perturbation、physics-based modeling、ML property prediction、enterprise informatics 和 project workflow 组合成药物发现软件栈。客户可以把它嵌入 medchem、structure-based design、lead optimization 和 compound prioritization。

赚钱方式分两层。第一层是软件 license / enterprise agreement，收入更接近 vertical scientific software；第二层是 discovery collaboration 和管线权益，可能带来 upfront、milestone、royalty 或候选物推进价值。公开报道的 Novartis 合作显示，药企愿意为平台技术和更广泛软件部署同时付费，这比单纯 SaaS 更接近“software + biotech option”。

估值逻辑也因此是混合型：软件业务看 ARR、续费、毛利和客户渗透；合作业务看 upfront 和项目进展；管线业务看临床阶段和 RNPV。与传统 biotech 相比，Schrödinger 的下行有软件收入支撑，上行来自合作和管线，但平台溢价需要持续由客户使用和项目推进证明。

5.2 AI-CRO / Platform Service: XtalPi

XtalPi 的 case 说明 AI 医药公司可以不承担完整临床资产风险，而通过 AI、量子化学、云计算、自动化实验和机器人平台为 pharma 提供研发服务。其业务更偏 early discovery、solid-state、crystal form、formulation、materials 和自动化实验基础设施。

软件/平台实现包括 molecular structure calculation、crystal prediction、formulation screening、robotics experiment execution、data feedback loop 和项目管理系统。客户获得的是筛选结果、晶型/制剂/材料方案和实验数据，而不只是算法输出。公司通过项目服务、平台合作和自动化实验能力收费。

估值逻辑更接近“高技术 CRO + 自动化平台 + 数据资产”。优点是收入路径较早、客户痛点明确、临床二元风险较低；缺点是毛利率、规模化、客户定制和服务属性会限制平台估值。XtalPi 的 IPO 给了市场一个中国 AI+robotics R&D infrastructure 的公开定价样本。

5.3 Platform Collaboration: Recursion 与 Isomorphic Labs

Recursion 的核心是 phenomics data factory：通过高通量细胞成像、扰动实验和机器学习，把细胞状态转化为可计算表征，再用于 target discovery、drug repurposing 和 mechanism mapping。其 Roche/Genentech、Bayer、NVIDIA 等合作/投资信号说明，大药企和技术公司愿意为大规模生物学数据平台买单。

Isomorphic Labs 代表 foundation-model biology 路线。其 AlphaFold/Drug Design Engine 叙事吸引 Novartis、Lilly 等合作，并获得外部融资。它的产品不是传统 SaaS，而是 AI drug design engine + partnership model：平台参与多个 early discovery program，未来价值来自项目推进、milestone 和可能的资产权益。

Platform collaboration 的估值重点是合作质量而非 headline 数字。强信号包括明确 upfront、committed research funding、一线 pharma partner、多个 program、重复合作、IND/clinical 进展和平台公司保留 downstream economics。弱信号是只披露“up to”总额、没有 upfront、没有项目边界、没有后续进展。

5.4 Asset-centric AI Biotech: Insilico Medicine

Insilico Medicine 是 asset-centric AI biotech 的典型例子。它把 AI 用于 target discovery、generative chemistry、lead optimization 和临床资产推进，核心商业逻辑不是卖工具，而是把 AI 平台转化为自有或合作资产。Rentosertib/ISM001-055 这类 AI-linked clinical asset 是它区别于普通软件公司的关键。

软件实现上，Insilico 路线通常包括 disease biology engine、target identification、generative chemistry、ADMET/DMTA optimization 和 clinical development package。它的价值链跨越 discovery 到 clinical，因此资产质量会反向证明平台能力：若多个资产进入 IND/Phase I/Phase II，平台溢价才更稳。

估值逻辑接近传统 biotech + 平台溢价。传统部分看 target、indication、IP、CMC、临床设计、安全性和 PoC；AI 增量看项目产出效率、candidate quality、pipeline breadth、合作/授权能力和平台复用性。若临床资产失败，平台叙事会被重新折价。

5.5 Full-stack AI Biotech: Recursion 与 Xaira

Full-stack AI biotech 试图把数据生成、模型、自动化实验、药物发现、临床开发和 BD 组合成 R&D operating system。Recursion 是上市公司案例，Xaira 则代表新一代大额融资的 foundation biology 公司。Xaira 过亿美元级别融资反映资本仍愿意押注“AI + 顶尖生物学团队 + 大规模平台”的公司形态。

这类公司的共同点是：自建或获取 proprietary data；把 wet lab 和模型迭代做成闭环；同时推进内部管线与外部合作；吸引跨学科团队；需要大量资本支撑基础设施和管线。它们与传统 biotech 的差异在于，多资产平台和数据飞轮可能降低单资产风险；但临床失败、烧钱速度和组织复杂度仍然会压制估值。

估值可拆成四块：现金与合作收入、平台/数据价值、风险调整管线价值、BD option value。若缺少临床数据，估值主要依赖平台可信度和融资 syndicate；若已有临床资产，市场会越来越按传统 biotech 标准重估。

5.6 Clinical / Regulatory / CMC Infrastructure: Saama、XtalPi 与 PV/RWE 软件

Clinical/regulatory/CMC infrastructure 公司不一定拥有药物资产，但可能更早形成可持续收入。Saama 类 clinical AI 平台的价值在于 patient matching、site selection、enrollment forecasting、trial analytics 和 clinical operations command center。PV/RWE 软件公司的价值在于 case processing、signal detection、RWE cohort、label expansion 和 post-market commitment tracking。

XtalPi 在 CMC/formulation/solid-state 场景也属于 infrastructure case。它的客户不是只买算法，而是买计算、自动化实验、晶型/制剂筛选和数据闭环。对于 pharma 来说，这些工作流可以减少返工、提高放大成功率、提高质量体系效率。

估值逻辑更接近 regulated vertical software / tech-enabled service。指标包括 enterprise deployment、客户留存、GxP validation、audit trail、系统集成、实施周期、项目 ROI 和毛利率。与传统 drug developer 相比，这类公司上行较少来自单个临床资产，但下行也不完全受临床二元事件支配。

5.7 NewCo / Venture Studio: AION Labs

AION Labs 是 AI 药物研发 venture studio / NewCo 模式的典型参照。它由 pharma、云厂商和投资机构共同支持，围绕药企明确提出的研发问题孵化 AI 公司，例如 antibody design、molecular glue、RNA targeting 等方向。这个模式的特点是从 pharma pain point 出发，而不是先有技术再找应用。

软件实现由每个 NewCo 自己承担，但 studio 提供的是 problem definition、数据/专家网络、初始资本、pharma validation 和治理结构。与普通创业公司相比，NewCo 一开始就有更明确的产业问题和潜在客户；与 pharma 内部项目相比，它又能用 VC 机制吸引创业团队和外部资本。

估值变量包括：NewCo 是否拥有独立 IP；数据和模型改良权归属是否清楚；pharma 是否有 option-to-buy；项目是否能独立融资；资产权益、royalty 和治理结构是否平衡。若权益设计不清，NewCo 容易变成外包服务；若设计得当，它能把 AI 平台能力转化为可融资资产。

5.8 投融资成功公司的共同点与估值差异


从 Schrödinger、Recursion、Isomorphic、Insilico、XtalPi、Xaira、Absci、AION Labs 等 case 看，获得融资或 BD 验证的公司通常具备至少两个条件：一是 AI 不停留在模型展示，而嵌入可交付软件、实验闭环、临床/监管 workflow 或资产管线；二是有外部验证，包括上市、融资、一线 pharma 合作、明确 upfront、企业客户或临床资产。

AI 赋能公司和传统药物研发公司的估值差异主要体现在平台层。传统 biotech 的估值以资产 RNPV 为核心，受单个临床读数影响大；AI 公司可能叠加软件收入倍数、数据资产溢价、平台复用溢价、BD option value 和多资产生成能力。但这些溢价不是永久的，必须由收入、合作、候选药和临床数据持续验证。

一个更实用的 VC 打分框架包括六层：技术是否具体落地为软件/平台；数据是否 proprietary 且可闭环；是否有真实客户或 pharma partner；是否保留资产权益；是否已有 candidate/IND/clinical 证据；估值是否与证据阶段匹配。最危险的公司类型是只有模型 demo、没有数据闭环、没有客户复购、没有资产权益，却按 full-stack biotech 估值融资。

Section 6: 当前趋势总结与未来格局预测

本节不是重新概括“AI 很热”，而是把前五节拉回同一个判断框架：Section 1 说明传统创新药研发的核心瓶颈在临床失败、CMC/监管复杂性和资本消耗；Section 2 显示公开热度集中在 discovery，但监管和 BD 资料提示 regulated workflow 的商业化更清晰；Section 3 展示 AI 已经嵌入从 TPP 到 PV/RWE 的多个环节；Section 4 和 5 则说明真实公司能否获得融资、BD 或估值溢价，取决于 AI 是否落地为软件、实验闭环、资产权益或企业级 workflow。



6.1 过去预期

上一轮 AI 药物研发叙事把重点放在“AI 自动发现药物”“显著缩短研发周期”“显著降低研发成本”“AI-native biotech 颠覆 pharma”。这些预期把 discovery 端的搜索效率提升，外推成全流程成功率提升。但 Section 1 已经说明，创新药价值链的主要损耗并不只在 hit discovery，而是在 target biology、candidate developability、Phase II PoC、Phase III 执行、CMC 放大、监管材料和商业化差异化。

从公司案例看，早期市场更容易奖励“平台想象力”：Recursion 的 phenomics 数据工厂、Insilico 的生成式小分子平台、Isomorphic 的 foundation-model biology、XtalPi 的 AI+robotics 自动化实验，都是把 AI 叙事推向平台估值的例子。但随后市场开始要求更具体的验证：软件是否有人付费，合作是否有 upfront，管线是否进入 IND/临床，平台是否能跨多个项目复用，现金消耗是否可控。

这意味着过去预期中最需要修正的部分，是把“AI 能生成候选分子”直接等同于“AI 能改变药物研发经济模型”。更合理的表达是：AI 已经在若干局部环节提高效率，并在少数公司中转化为 BD、融资、IPO 或临床资产；但它尚未在行业层面证明可以系统性提高药物获批概率。投资判断要从“AI 是否先进”转为“AI 是否作用于最贵、最慢、最容易失败的环节”。

6.2 当前现实

当前最扎实的商业现实有三类。第一类是 software / platform revenue，例如 Schrödinger 的计算药物发现软件和企业协议，XtalPi 的自动化实验与晶型/制剂服务，clinical/regulatory/PV 软件的 enterprise deployment。它们的价值更接近 vertical software 或 tech-enabled service，优点是收入较早出现，缺点是平台估值上限受收入规模、毛利和客户集中度限制。

第二类是 pharma platform collaboration，例如 Schrödinger-Novartis、Recursion-Roche/Genentech、Isomorphic-Novartis/Lilly 等。这里的关键不是新闻稿里的 headline value，而是 upfront、research funding、项目数量、合作范围、下游权益和后续项目推进。一个有明确 upfront、多个项目和企业级部署的合作，商业验证强于一个只披露“up to”总金额但没有项目进展的合作。

第三类是 asset-centric AI biotech，例如 Insilico 把 AI discovery 叙事推进到临床资产，Exscientia 等公司也曾代表 AI-designed / AI-selected asset 的临床路径。进入临床后，市场会越来越按传统 biotech 标准评估 target、indication、IP、CMC、安全性和 PoC，而不是单独按 AI 模型估值。AI 平台溢价只有在多个资产反复证明 candidate quality 或临床转化效率时才会稳定。

当前最大的现实约束也很清楚。Discovery 提效相对成立，但 clinical success uplift 尚未充分证明；AI 生成分子并不能自动解决 ADMET、toxicity、CMC 和 patient selection；foundation model biology 具有长期潜力，但需要药企合作项目和临床资产把潜力兑现；regulated workflow 更容易赚钱，但估值可能更像企业软件而不是爆发式 biotech。

6.3 未来趋势

未来 3-5 年，更容易商业化的方向会集中在“有明确预算和可量化 ROI”的场景：clinical operations、patient matching、site selection、regulatory writing、PV automation、RWE evidence generation、CMC/formulation/process analytics、小分子 closed-loop lead optimization。这些方向未必最性感，但买方明确，交付物清楚，销售对象在 pharma 内部已有预算。

未来 5-10 年，上限更高的方向来自“AI 形成资产权益”的场景：foundation-model biology、multi-omics target discovery、AI-enabled small molecule pipeline、antibody/protein design、RNA/gene delivery、ADC therapeutic index、cell therapy manufacturing + patient selection、radiopharma dosimetry and patient selection。这些方向的估值上限更接近 biotech，但验证周期更长，失败风险也更高。

公司形态上，行业可能不会出现单一赢家，而会分化成四类。第一类是 enterprise workflow infrastructure，服务临床、监管、CMC、PV/RWE。第二类是 AI+automation 数据工厂，例如 Recursion、XtalPi 这种把实验数据工业化的平台。第三类是 asset-centric AI biotech，例如 Insilico 式自研资产公司。第四类是 foundation-model biology / full-stack platform，例如 Isomorphic、Xaira 这类资本密集型平台。

对 VC 来说，未来趋势的核心不是押注“AI 药物研发”这个大词，而是判断公司处在哪个变现路径：卖软件、卖服务、卖合作项目、卖资产权益，还是卖一个长期数据飞轮。不同路径的估值方法完全不同，不能用同一个平台故事覆盖所有公司。

6.4 最可能胜出的公司类型

第一类胜出者是有 proprietary data 和 wet-lab closed loop 的平台。Recursion 的高通量细胞成像和扰动数据、XtalPi 的自动化实验和晶型/制剂数据、某些抗体或 RNA 平台的实验反馈数据，都是比单纯算法更难复制的资产。数据闭环使模型不是一次性工具，而是可以随项目积累而变强的系统。

第二类胜出者是能把 AI 转化为真实资产权益的公司。Insilico 这类公司如果能不断把 target discovery 和 generative chemistry 推到 candidate、IND、Phase I/II，就会从“AI 工具公司”转向“平台型 biotech”。这类公司估值上限高，但也必须接受传统 biotech 的临床失败风险。

第三类胜出者是 regulated workflow infrastructure。Regulatory writing、PV、RWE、CMC、clinical operations 这些环节不一定产生明星药物资产，但可以形成稳定预算、系统嵌入和企业续费。对基金组合而言，这类公司可作为比 asset biotech 风险更低的 AI 医药配置。

第四类胜出者是能持续获得高质量 pharma collaboration 的平台。Schrödinger、Recursion、Isomorphic 等案例说明，大药企愿意为可复用平台付费。但可持续合作要求平台不断提供具体项目价值，而不是停留在技术演示。

6.5 最可能被淘汰或边缘化的公司类型

最脆弱的是只有模型 demo、没有 proprietary data、没有实验闭环、没有客户复购、没有资产权益的公司。随着开源模型、云平台和 pharma 内部 AI 团队能力增强，单一算法会快速商品化。没有数据和 workflow 的模型，很难形成长期定价权。


第二类风险是只有项目服务收入、却按平台估值融资的公司。如果收入高度依赖定制交付、毛利率低、每个客户都要重新开发，最终会更像 CRO 或咨询公司，而不是可扩展 AI 平台。除非服务过程沉淀 reusable data、workflow 和 downstream economics，否则估值应回到服务公司逻辑。

第三类风险是 headline BD 很大、但真实现金和项目边界不清的公司。AI 药物研发新闻稿常用“up to”数字放大合作规模，实际 upfront、research funding、option 条款和项目推进才决定商业含金量。缺少后续项目进展的 headline deal，不足以支撑长期平台溢价。

第四类风险是过早 full-stack 化但组织能力不足的公司。AI 团队若没有补齐药化、生物学、CMC、临床、法规、BD 和质量体系，很容易在进入 IND/临床后暴露短板。full-stack 不是口号，而是昂贵且复杂的组织能力。

Section 7: 总结

本节把全文沉淀为可执行的 VC 研究框架。框架直接落到六个问题：公司做的是哪一类 AI 应用，软件/平台如何落地，是否有客户或 BD，是否拿到资产权益，是否能跨项目复用，估值是否与验证阶段匹配。



7.1 当前格局总结

AI 已经成为创新药研发的横向基础设施，但不是一个统一赛道。Section 2 显示论文热度集中在 discovery，但 Section 4 和 5 的真实公司案例表明，商业化路径分散在软件、服务、平台合作、资产 biotech、full-stack biotech、clinical/regulatory/CMC infrastructure 和 NewCo 等多个模式。

最确定的价值是局部效率提升：更快筛选分子、更快整理文献和专利、更快做 trial feasibility、更快检查监管文档、更快处理 PV case、更快做 CMC/formulation 试验。最有上限的价值是资产质量提升：更好的 target、candidate、patient selection、dose、endpoint、therapeutic index 和 developability。但后者需要临床和项目级结果证明。

前文案例可以归纳成三条主线。Schrödinger 和 XtalPi 说明 AI 可以变成软件/基础设施收入；Recursion 和 Isomorphic 说明 AI 平台可以获得大药企合作；Insilico 说明 AI 可以尝试转化为临床资产。三条路径都成立，但估值方法不同，风险也不同。

7.2 VC 核心判断框架

第一步是判断公司到底卖什么。若卖软件，看 ARR、续费、部署深度和系统集成；若卖服务，看毛利、复购和是否沉淀数据；若卖平台合作，看 upfront、research funding、项目推进和下游权益；若卖资产，看 target、IP、CMC、临床设计和 PoC；若卖 full-stack 叙事，看资本效率和组织能力。

第二步是判断 AI 是否命中真实瓶颈。小分子 AI 要证明不只是生成分子，而是改善 lead/candidate quality；抗体/蛋白 AI 要证明 developability；RNA/gene AI 要证明 delivery 和 off-target；cell therapy AI 要证明制造一致性和患者选择；regulatory/PV/CMC AI 要证明 ROI、audit trail 和 GxP workflow。

第三步是拆解估值。AI 医药公司估值可拆成五层：现金和收入层，平台/数据层，资产管线层，BD option 层，团队和组织层。传统 biotech 主要集中在资产管线层；AI 公司若要获得额外溢价，就必须证明平台/数据层和 BD option 层是真实存在的。

尽调维度	具体要看什么	对应公司例子
软件收入	ARR、企业部署、续费、系统集成、用户深度	Schrödinger、clinical/regulatory/PV vendors
数据闭环	proprietary data、wet-lab/robotics feedback、跨项目复用	Recursion、XtalPi
资产权益	composition-of-matter、用途专利、共同开发权、royalty	Insilico、asset-centric AI biotech
BD 质量	upfront、research funding、项目数量、下游权益、后续进展	Schrödinger-Novartis、Recursion-Roche/Genentech、Isomorphic-Novartis/Lilly
regulated workflow	GxP、audit trail、source traceability、validation、human oversight	CMC/regulatory/PV infrastructure
资本效率	burn rate、临床投入、平台维护成本、融资可持续性	Recursion、Xaira、full-stack AI biotech

7.3 未来格局预测

短期最可能先跑出收入的，不一定是最会讲 discovery 故事的公司，而是能嵌入药企日常 workflow 的公司：clinical operations、regulatory writing、PV/RWE、CMC/formulation、trial intelligence、小分子 lead optimization。这些场景的预算明确，ROI 可量化，更容易从 pilot 变成 enterprise deployment。

中长期最可能跑出大市值的，是能把 AI 平台转化为多资产权益的公司。单个资产成功会带来 biotech upside；多个资产反复进入 IND/临床并形成 BD，会证明平台可重复。这个路径的难点是资本消耗高、临床风险高、周期长，对团队的药物开发能力要求远高于普通 AI 公司。

行业格局可能形成“平台公司 + pharma + CRO/CDMO + 数据公司 + NewCo”的分工。Pharma 不会完全外包研发判断，但会购买可验证的工具、数据、候选物和 workflow；CRO/CDMO 会把 AI 融入服务效率；AI biotech 会在资产权益和平台合作之间寻找平衡；VC 会通过 NewCo 或 co-development 把平台能力变成更清楚的资产结构。

7.4 Modality 横向结论

从 modality 角度看，AI 的投资含义不是“哪个药物类型最适合 AI”这么简单，而是每个 modality 的核心失败点不同。小分子最容易被 AI 快速产品化，因为数据、合成、assay 和 ADMET 反馈相对标准化，Schrödinger、Insilico、Exscientia 等公司已经形成软件、平台合作或资产型路径；但小分子也是竞争最拥挤的方向，估值需要回到 candidate quality、IND/clinical progress、IP/FTO 和 BD 现金结构。

抗体、蛋白药和双抗的 AI 上限来自结构预测、binding design、CDR optimization、developability 和免疫原性控制。Isomorphic、Absci 等案例说明 foundation model 和生成式蛋白设计已经吸引 pharma 合作，但该 modality 的真正验证点不是结构预测准确，而是表达、稳定性、聚集、CMC、免疫原性和临床差异化。换言之，biologics AI 的估值不能只按模型能力，而要看是否输出可制造、可临床转化的 biologics asset。

RNA、小核酸、基因治疗和基因编辑的共同瓶颈是 delivery、off-target、安全性和组织选择性。Deep Genomics、Dyno 等公司代表 AI 与 RNA biology、splicing、AAV capsid engineering、sequence optimization 的结合，但如果递送系统和体内验证不足，AI 只能停留在设计工具层。该类 modality 的投资上限很高，因为一旦解决 delivery 或 tissue tropism，可以跨多个 payload 和适应症复用；但验证周期和监管风险也显著高于小分子软件平台。

ADC、细胞治疗和核药属于“AI 可加速但公开验证仍早期”的高上限方向。ADC 的关键是 therapeutic index，而不是生成更多抗体或 linker-payload 组合；细胞治疗的关键是制造一致性、患者选择和实体瘤疗效；核药的关键是 dosimetry、影像分层、同位素供应和诊疗闭环。这些方向适合作为高风险高上限 watchlist，投资时应优先寻找已经拥有真实实验数据、制造能力、临床网络或 pharma collaboration 的团队，而不是只有模型概念的公司。

综合来看，短期组合中更适合配置小分子 closed-loop optimization、CMC/regulatory/PV infrastructure、clinical operations AI 和 XtalPi 式自动化实验平台；中长期组合中更适合跟踪 antibody/protein design、RNA/gene delivery、ADC therapeutic index、cell therapy manufacturing 和 radiopharma patient selection。不同 modality 对应不同估值方法：小分子看 candidate 和 BD，biologics 看 developability，RNA/gene 看 delivery，ADC 看治疗窗，cell therapy 看制造，核药看诊疗闭环。

7.5 最值得进一步研究的公司类型与细分方向

第一优先级是有临床或 IND-stage 资产的 AI-linked biotech，例如 Insilico、部分 Exscientia/Recursion 相关资产。这类公司最能检验 AI 是否从 discovery 效率走向资产价值。研究重点是 clinical trial design、patient population、endpoint、safety、CMC 和同类项目比较。

第二优先级是有真实收入或企业部署的 AI infrastructure，包括 Schrödinger、XtalPi、clinical operations AI、regulatory writing、PV/RWE、CMC/formulation 平台。研究重点是收入质量、客户集中度、续费、毛利、实施周期、GxP validation 和系统替换成本。

第三优先级是 foundation biology 和数据工厂公司，包括 Recursion、Isomorphic、Xaira、Deep Genomics、Dyno、Absci 等。研究重点是 proprietary data、wet-lab loop、平台复用性、合作条款、内部管线和资本效率。

第四优先级是高上限但公开验证早期的 modality-specific platform，包括 AI-enabled ADC、RNA delivery、gene editing delivery、cell therapy manufacturing、radiopharma dosimetry。研究重点不是“有没有 AI”，而是 AI 是否作用于该 modality 的核心失败点。

7.6 最终投资结论

AI 医药投资不能只分“AI 公司”和“传统 biotech”。更实用的分类是：AI software、AI-enabled service、AI platform collaboration、AI asset biotech、AI full-stack biotech、regulated workflow infrastructure。每一类都可以投资，但使用不同估值方法。

对早期 VC 而言，最优组合不是押注单一超级平台，而是组合配置：一部分投有收入和 workflow lock-in 的 infrastructure，一部分投有资产权益的 AI biotech，一部分投数据闭环强的 foundation biology / automation 平台。这样既能获得 AI 医药长期上行，也能降低单一临床资产失败带来的波动。

最终判断标准可以压缩成一句话：一家 AI 医药公司值得投，不是因为它用了 AI，而是因为 AI 让它获得了传统公司难以复制的数据、速度、成本结构、资产权益或客户嵌入。若这些优势不能被收入、BD、候选药、临床结果或监管级 workflow 验证，AI 标签本身不应带来估值溢价。

关键来源

- FDA. Using Artificial Intelligence & Machine Learning in the Development of Drug & Biological Products. <https://www.fda.gov/media/167973/download>
- FDA. Considerations for the Use of Artificial Intelligence to Support Regulatory Decision-Making for Drug and Biological Products. <https://www.fda.gov/media/184830/download>
- EMA. Reflection paper on the use of Artificial Intelligence in the medicinal product lifecycle. https://www.ema.europa.eu/en/documents/scientific-guideline/reflection-paper-use-artificial-intelligence-ai-medicinal-product-lifecycle_en.pdf
- EU. Regulation (EU) 2024/1689, Artificial Intelligence Act. <https://eur-lex.europa.eu/eli/reg/2024/1689/oj>
- BIO / QLS Advisors / Informa. Clinical Development Success Rates and Contributing Factors 2011-2020.
- Wong CH, Siah KW, Lo AW. Estimation of clinical trial success rates and related parameters. <https://doi.org/10.1093/biostatistics/kxx069>
- Wouters OJ, McKee M, Luyten J. Estimated R&D investment needed to bring a new medicine to market. <https://jamanetwork.com/journals/jama/fullarticle/2762311>
- Jumper J et al. Highly accurate protein structure prediction with AlphaFold. <https://doi.org/10.1038/s41586-021-03819-2>
- Abramson J et al. Accurate structure prediction of biomolecular interactions with AlphaFold 3. <https://doi.org/10.1038/s41586-024-07487-w>
- Stokes JM et al. A Deep Learning Approach to Antibiotic Discovery. <https://doi.org/10.1016/j.cell.2020.01.021>
- Zhavoronkov A et al. Deep learning enables rapid identification of potent DDR1 kinase inhibitors. <https://doi.org/10.1038/s41587-019-0224-x>
- Vamathevan J et al. Applications of machine learning in drug discovery and development. <https://doi.org/10.1038/s41573-019-0024-5>
- Chen H et al. The rise of deep learning in drug discovery. <https://doi.org/10.1016/j.drudis.2018.01.039>
- Bian Y, Xie XQ. Generative chemistry: drug discovery with deep learning generative models. <https://arxiv.org/abs/2008.09000>
- Hasselgren C, Oprea TI. Artificial Intelligence for Drug Discovery: Are We There Yet? <https://arxiv.org/abs/2307.06521>
- Subramanian A et al. Automated patent extraction powers generative modeling in focused chemical spaces. <https://arxiv.org/abs/2303.08272>
- Wang X et al. PatentAgent: Intelligent Agent for Automated Pharmaceutical Patent Analysis. <https://arxiv.org/abs/2410.21312>
- Shi Y et al. Intelligent System for Automated Molecular Patent Infringement Assessment. <https://arxiv.org/abs/2410.21312>

[g/abs/2412.07819](https://www.wipo.int/publications/en/details.jsp?id=4711)

- WIPO. Getting the innovation ecosystem ready for AI: An IP policy toolkit. <https://www.wipo.int/publications/en/details.jsp?id=4711>
- MarketWatch. Schrödinger-Novartis collaboration terms reported in 2024. <https://www.marketwatch.com/story/schrodingers-stock-soars-9-as-it-enters-collaboration-pact-with-novartis-for-up-to-about-2-5-billion-in-payments-f2f30aed>
- Axios. Xaira Therapeutics launches with over \$1B funding. <https://www.axios.com/2024/04/24/stanford-ai-biotech-xaira>
- Wall Street Journal. XtalPi / QuantumPharm Hong Kong IPO coverage. <https://www.wsj.com/articles/tencent-backed-ai-drug-researcher-gains-in-hong-kong-debut-3ba50951>
- Public company and company-disclosure follow-up required for Recursion, Isomorphic Labs, Insilico Medicine, Absci, Deep Genomics, Dyno Therapeutics, Cellares, AION Labs and Ratio Therapeutics; secondary sources are used only as discovery signals where primary terms were not fully accessible.